BeautifulSoup

A. Apartado A

1) Utilizando Beautifulsoup, de las citas que se encuentran en el siguiente enlace: https://quotes.toscrape.com/, extrae y almacena en un fichero JSON que llamaremos “citas_A.josn” los siguientes datos: Id (número secuencial que generará el programa), autor (nombre del autor), cita (texto de la cita), etiquetas (array con las tags), tamaño (longitud del texto de la etiqueta)

Extraeremos todos los div de clase “quote” hijos del div de clase “col-md-8”.

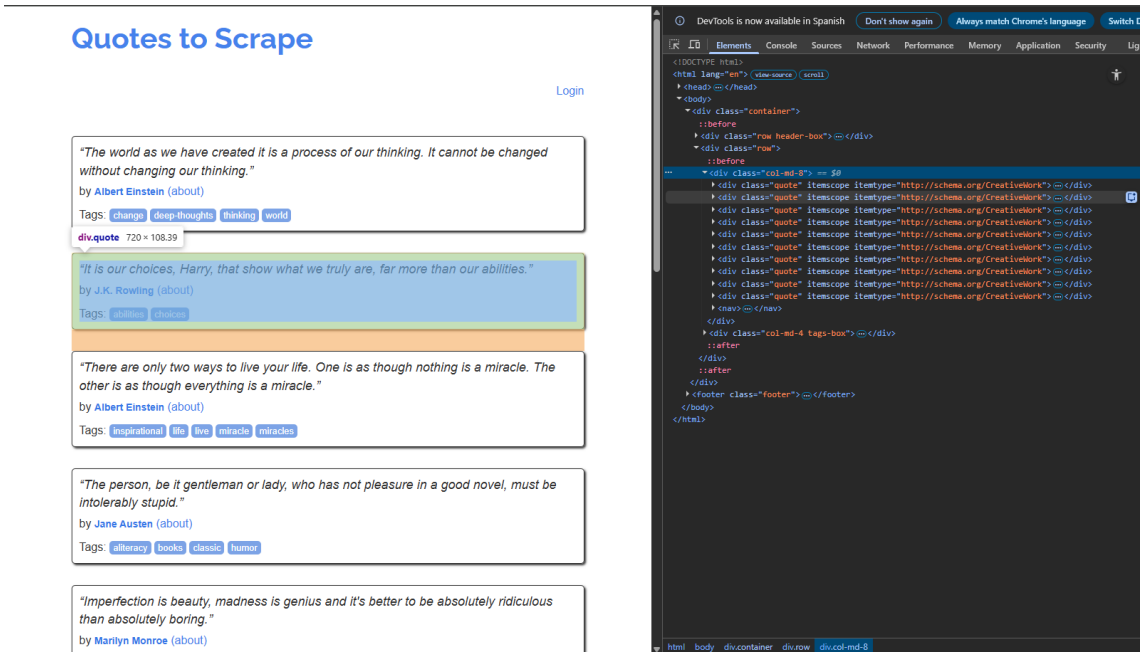


```python
from urllib.request import urlopen
from urllib.error import HTTPError
from bs4 import BeautifulSoup

import json

url = r"https://quotes.toscrape.com/"

try:
    html = urlopen(url)
except HTTPError as e:
    print("Página no encontrada")

bs = BeautifulSoup(html.read(), 'html.parser')

try:
```

```
    padre_quotes = bs.find_all('div', attrs={'class': ['row', 'header-
box']})[1].find('div', attrs={'class': 'col-md-8'})
except AttributeError as e:
    print("Etiqueta no encontrada")

try:
    quotes = padre_quotes.find_all('div', attrs={'class': ['row', 'quote']})
except AttributeError as e:
    print("Etiqueta no encontrada")

quotes_data = []
id_cont = 1
for quote in quotes:
    # Reseteamos los datos
    quote_data = {"id": 0, "autor": "", "cita": "", "etiquetas": [],
"tamano": 0}

    # Id
    quote_data["id"] = id_cont
    id_cont += 1

    # Autor
    autor = quote.find('small', attrs={'class': 'author'}).string
    quote_data["autor"] = autor

    # Cita
    cita = quote.find('span', attrs={'class': 'text'}).string
    quote_data["cita"] = cita

    # Etiquetas
    etiquetas_html = quote.find('div', attrs={'class': 'tags'}).find_all('a',
attrs={'class': 'tag'})
    etiquetas = []
    for etiqueta in etiquetas_html:
        etiquetas.append(etiqueta.string)
    quote_data["etiquetas"] = etiquetas

    # Tamaño
    quote_data["tamano"] = len(cita)

    # Lo insertamos
    quotes_data.append(quote_data)

with open(r"./json/citas_A.json","w") as archivo:
    json.dump(quotes_data, archivo, indent=4)
```

Resultado

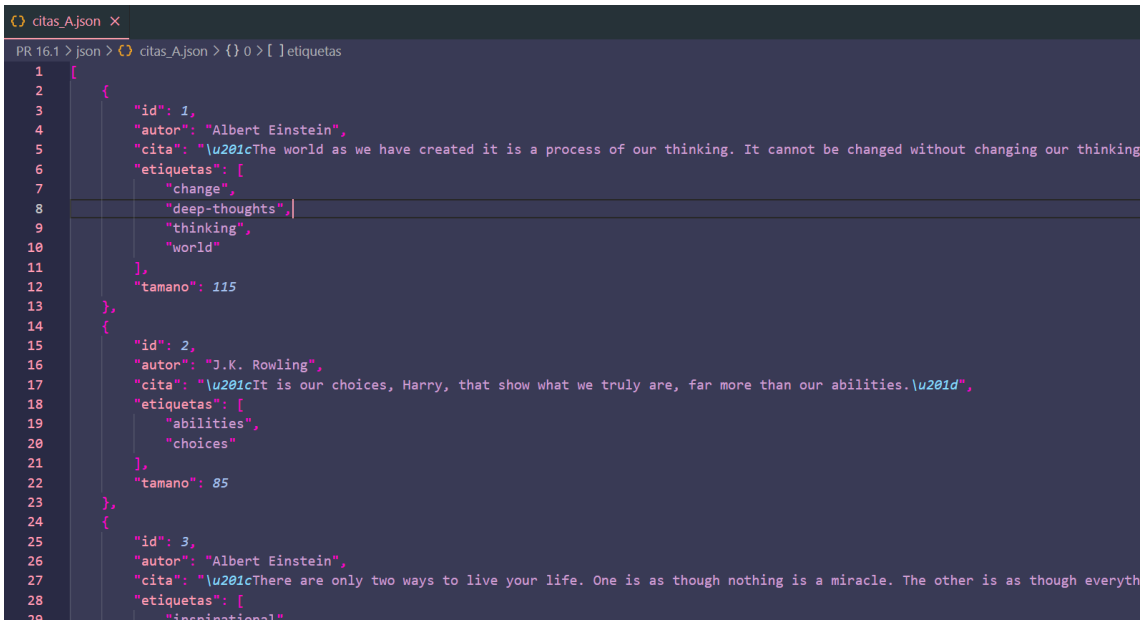


```
[
    {
        "id": 1,
        "autor": "Albert Einstein",
        "cita": "\u201cThe world as we have created it is a process of our thinking. It cannot be changed without changing our thinking
        "etiquetas": [
            "change",
            "deep-thoughts",
            "thinking",
            "world"
        ],
        "tamano": 115
    },
    {
        "id": 2,
        "autor": "J.K. Rowling",
        "cita": "\u201cIt is our choices, Harry, that show what we truly are, far more than our abilities.\u201d",
        "etiquetas": [
            "abilities",
            "choices"
        ],
        "tamano": 85
    },
    {
        "id": 3,
        "autor": "Albert Einstein",
        "cita": "\u201cThere are only two ways to live your life. One is as though nothing is a miracle. The other is as though everyth
        "etiquetas": [
```


B. Apartado B

1) Partiendo del ejercicio anterior, para cada cita, siguiendo y analizando el enlace que nos lleva a la página del autor (about), añade al JSON del ejercicio anterior los siguientes campos: Fecha (fecha de nacimiento del autor), localidad (localidad de nacimiento del autor) y url (dirección del enlace de su página). Almacena los datos en un fichero JSON que llamaremos “citas_B.josn”

Extraeremos el valor del atributo “href” de la etiqueta “a”.

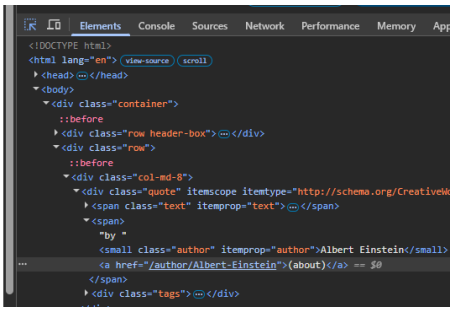

Abrimos la dirección. De ella, extraemos los valores de dos etiquetas “span”. Las de clases “author-born-date” y “author-born-location”.

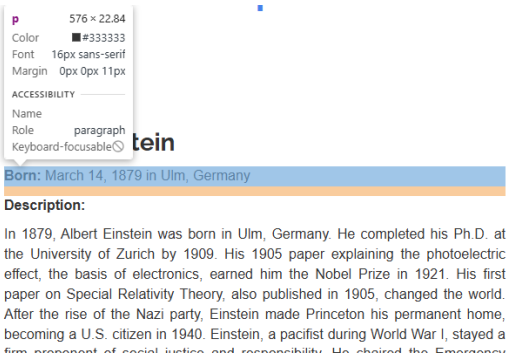

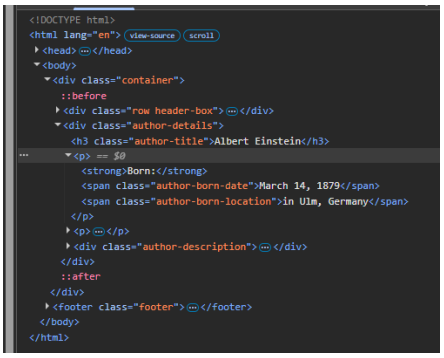


```
from urllib.request import urlopen
from urllib.error import HTTPError
from bs4 import BeautifulSoup

import json

url = r"https://quotes.toscrape.com/"

try:
    html = urlopen(url)
except HTTPError as e:
    print("Página no encontrada")

bs = BeautifulSoup(html.read(), 'html.parser')

try:
    padre_quotes = bs.find_all('div', attrs={'class': ['row', 'header-
box']})[1].find('div', attrs={'class': 'col-md-8'})
except AttributeError as e:
    print("Etiqueta no encontrada")

try:
    quotes = padre_quotes.find_all('div', attrs={'class': ['row', 'quote']})
except AttributeError as e:
    print("Etiqueta no encontrada")

quotes_data = []
id_cont = 1
for quote in quotes:
    # Reseteamos los datos
    quote_data = {"id": 0, "autor": "", "cita": "", "etiquetas": [],
"tamano": 0}

    # Id
    quote_data["id"] = id_cont
    id_cont += 1

    # Autor
    autor = quote.find('small', attrs={'class': 'author'}).string
    quote_data["autor"] = autor
```

```
    # Cita
    cita = quote.find('span', attrs={'class': 'text'}).string
    quote_data["cita"] = cita

    # Etiquetas
    etiquetas_html = quote.find('div', attrs={'class': 'tags'}).find_all('a',
attrs={'class': 'tag'})
    etiquetas = []
    for etiqueta in etiquetas_html:
        etiquetas.append(etiqueta.string)
    quote_data["etiquetas"] = etiquetas

    # Tamaño
    quote_data["tamano"] = len(cita)

    # Obtenemos la información avanzada del autor
    autorUrl = quote.a.attrs['href']

    try:
        htmlAutor = urlopen(f"{url}{autorUrl}")
        bsAutor = BeautifulSoup(htmlAutor.read(), 'html.parser')

        quote_data["fechaAutor"] = bsAutor.find('span', {'class': "author-
born-date"}).string
        quote_data["localidadAutor"] = bsAutor.find('span', {'class':
"author-born-location"}).string.removeprefix("in ")

    except HTTPError as e:
        print(f"Detalles de {autor} no encontrados")

    # Lo insertamos
    quotes_data.append(quote_data)

with open(r"./json/citas_B.json","w") as archivo:
    json.dump(quotes_data, archivo, indent=4)
```

Resultado:

```
citas_B.json ×
PR 16.1 > json > citas_B.json > {} 0 > localidadAutor
1  [
2      {
3          "id": 1,
4          "autor": "Albert Einstein",
5          "cita": "\u201cThe world as we have created it is a process of our thinking. It cannot be changed without changing our thinking.
6          "etiquetas": [
7              "change",
8              "deep-thoughts",
9              "thinking",
10             "world"
11         ],
12         "tamano": 115,
13         "fechaAutor": "March 14, 1879",
14         "localidadAutor": "Ulm, Germany"
15     },
16     {
17         "id": 2,
18         "autor": "J.K. Rowling",
19         "cita": "\u201cIt is our choices, Harry, that show what we truly are, far more than our abilities.\u201d",
20         "etiquetas": [
21             "abilities",
22             "choices"
```


C. Apartado C

1) Siguiendo el botón el enlace del botón Next que viene al final de la página de citas (por ejemplo, para la segunda página su URL es https://quotes.toscrape.com/page/2/) extrae ahora todas las citas que aparecen en el sitio incluyendo como en el ejercicio anterior los datos del autor. Almacena los datos en un fichero JSON que llamaremos "citas_C.josn".

Ejecutamos el programa extrayendo en bucle los datos de todas las páginas. Para detectar que hemos terminado, observaremos en cada página si la etiqueta "div" de atributo "col-md-8" no está.

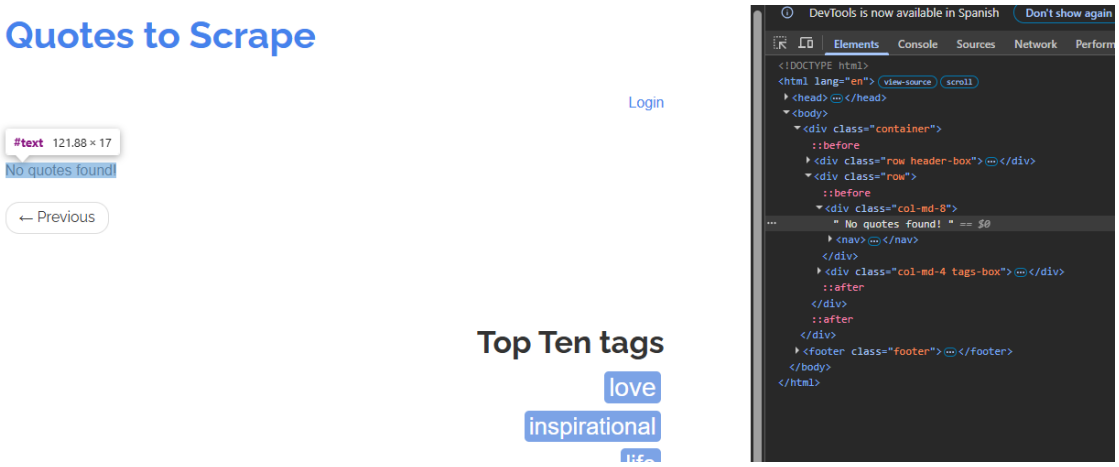

El programa ha sido totalmente modificado

```
from urllib.request import urlopen
from urllib.error import HTTPError
from bs4 import BeautifulSoup

import json
```

```
url = r"https://quotes.toscrape.com/"

pagina_cont = 1
seguir = True
id_cont = 1
quotes_data = []

while seguir:
    pagina_cont += 1
    try:
        htmlPagina =
urlopen(f"https://quotes.toscrape.com/page/{pagina_cont}/")
    except HTTPError as e:
        print("Página no encontrada")

    bsPagina = BeautifulSoup(htmlPagina.read(), 'html.parser')

    try:
        padre_quotes = bsPagina.find_all('div', attrs={'class': ['row',
'header-box']})[1].find('div', attrs={'class': 'col-md-8'})
    except AttributeError as e:
        print("Etiqueta no encontrada")

    try:
        quotes = padre_quotes.find_all('div', attrs={'class': ['row',
'quote']})

    except AttributeError as e:
        print("Etiqueta no encontrada")
        seguir = False

    if seguir:

        for quote in quotes:
            # Reseteamos los datos
            quote_data = {"id": 0, "autor": "", "cita": "", "etiquetas": [],
"tamano": 0}

            # Id
            quote_data["id"] = id_cont
            id_cont += 1

            # Autor
            autor = quote.find('small', attrs={'class': 'author'}).string
            quote_data["autor"] = autor

            # Cita
            cita = quote.find('span', attrs={'class': 'text'}).string
            quote_data["cita"] = cita
```

```
            # Etiquetas
            etiquetas_html = quote.find('div', attrs={'class':
'tags'}).find_all('a', attrs={'class': 'tag'})
            etiquetas = []
            for etiqueta in etiquetas_html:
                etiquetas.append(etiqueta.string)
            quote_data["etiquetas"] = etiquetas

            # Tamaño
            quote_data["tamano"] = len(cita)

            # Obtenemos la información avanzada del autor
            autorUrl = quote.a.attrs['href']

            try:
                htmlAutor = urlopen(f"{url}{autorUrl}")
                bsAutor = BeautifulSoup(htmlAutor.read(), 'html.parser')

                quote_data["fechaAutor"] = bsAutor.find('span', {'class':
"author-born-date"}).string
                quote_data["localidadAutor"] = bsAutor.find('span', {'class':
"author-born-location"}).string.removeprefix("in ")

            except HTTPError as e:
                print(f"Detalles de {autor} no encontrados")

            # Lo insertamos
            quotes_data.append(quote_data)

with open(r"./json/citas_C.json","w") as archivo:
    json.dump(quotes_data, archivo, indent=4)
```

Resultado:

citas_C.json

PR 16.1 > json > citas_C.json > {} 27


```
339     },
340     {
341         "id": 27,
342         "autor": "Albert Einstein",
343         "cita": "\u201cIf you want your children to be intelligent, read them fairy tales. If yo
344         "etiquetas": [
345             "children",
346             "fairy-tales"
347         ],
348         "tamano": 138,
349         "fechaAutor": "March 14, 1879",
350         "localidadAutor": "Ulm, Germany"
351     },
352     {
353         "id": 28,
354         "autor": "J.K. Rowling",
355         "cita": "\u201cIt is impossible to live without failing at something, unless you live so
356         "etiquetas": [],
357         "tamano": 169,
358         "fechaAutor": "July 31, 1965",
359         "localidadAutor": "Yate, South Gloucestershire, England, The United Kingdom"
360     },
361     {
362         "id": 29,
363         "autor": "Albert Einstein",
364         "cita": "\u201cLogic will get you from A to Z; imagination will get you everywhere.\u201
365         "etiquetas": [
366             "imagination"
367         ],
```